

第十一届全国大学生生物医学工程创新设计竞赛

预赛作品报告模板

基于深度迁移学习与手工特征融合的脑电 情绪识别方法

作品 ID 号:

参赛学生类型: 本科生

参加赛道: 命题项目组

组别: 命题项目组

2026 年 5 月

请勿在作品中出现参赛者及指导教师相关学校及个人信息，否则不予评审

内容完整性自查表

说明：

- 1. 命题组参赛作品请根据命题文件规定或要求的指标填写；
- 2. 自选组参赛作品请根据实际参赛作品完成情况填写。

完整性类别	任务或技术指标名称	完成效果	呈现方式 (报告中的章节、页码， 或者测试报告，或实物、 视频等)
参赛作品 任务或技术 指标要求	1.		
	2.		
	3.		
	4.		
	5.		
	6.		
	7.		
	8.		
其他			

摘 要

摘要是项目报告不加注释和评论的简短陈述，应以第三人称陈述。它应具有独立性和自含性，即不阅读报告的全文，就能获得必要的信息，摘要的内容应包含与项目报告同等量的主要信息，供读者确定有无必要阅读全文。

摘要一般应说明研究工作目的、实验研究方法、结果和最终结论等，而重点是结果和结论。摘要中一般不用图、表、化学结构式、计算机程序，不用非公知公用的符号、术语和非法定的计量单位。

摘要一般为 300–400 汉字左右，用小四号宋体。

关键词是为了文献标引工作从项目报告中选取出来用以表示全文主题内容信息款目的单词或术语。一般项目报告应选取 3–5 个词作为关键词，关键词间用逗号隔开，最后一个词后不打标点符号。以显著的字符排在同种语言摘要的下方。如有可能，尽量用《汉语主题词表》等词表提供的规范词。

关键词：XXX, XXX, XXX, XXX, XXX (3–5 个，逗号分隔，末尾不加符号)

目 录

摘要	I
1 作品概述	1
1.1 背景及意义	1
1.2 研究基础	1
1.3 研究目标	1
2 作品方案设计及实现	3
2.1 技术路线概述	3
2.2 数据预处理	3
2.3 手工特征与 LightGBM	4
2.4 EEGNet 深度模型与迁移学习	4
2.4.1 EEGNet 架构	4
2.4.2 迁移学习策略	4
2.5 模型融合	5
3 作品测试方案及测试结果	6
3.1 测试方案	6
3.2 对比实验分析	6
3.3 消融实验分析	7
3.4 训练过程分析	7
3.5 测试集推理	9
4 总结	10
4.1 核心技术成果	10
4.2 展望	10

1 作品概述

1.1 背景及意义

情绪识别在人机交互、心理健康评估和医学诊断等领域具有重要应用价值。与传统基于面部表情或语音的情绪识别方法相比，脑电信号直接从大脑皮层采集，能够更客观地反映人的真实情感状态，难以被主观掩饰，被誉为情绪识别的“金标准”。

然而，基于脑电的情绪识别面临三大核心挑战：(1) **高维度低样本量**：单次 EEG 记录包含 30 通道 × 数千时间点的高维数据，但可用被试数量通常较少（本赛题 60 人），深度学习模型极易过拟合；(2) **跨被试泛化困难**：不同被试的脑电信号存在巨大的个体差异（电极位置、颅骨厚度、基线脑活动等），同一模型在不同被试上的表现可能大幅波动；(3) **信号信噪比低**：EEG 信号易受眼电、肌电、运动伪迹等噪声干扰，情绪相关的微弱有用信号往往被淹没。

本作品围绕上述挑战，设计并实现了一套**深度迁移学习与手工特征融合**的脑电情绪识别方案。

1.2 研究基础

近年来，多种深度学习架构已被用于脑电情绪识别。EEGNet[2] 通过深度可分离卷积实现参数高效的空间-时间特征提取；TSception[1] 引入多尺度时间卷积与非对称空间卷积，分别捕捉不同频率的 EEG 动态特征以及左右脑半球的不对称模式；ATCNet 和 STAFNet 则进一步集成了注意力机制与图神经网络，在 SEED、DEAP 等公开数据集上取得了领先性能。

DEAP[3] 是目前应用最广泛的脑电情绪公开数据集之一，包含 32 名被试观看 40 段音乐视频后记录的 32 通道脑电信号及 Valence-Arousal 四维情绪标注。LightGBM[4] 是一种基于梯度提升决策树的高效集成学习方法。

1.3 研究目标

本项目旨在解决小样本跨被试脑电情绪分类任务，核心创新点如下：

1. **跨数据集迁移学习**：利用 DEAP 公开数据集进行预训练，将学到的通用 EEG 情绪表征迁移至竞赛数据集的二分类任务，缓解小样本过拟合问题。
2. **手工特征与深度学习融合**：提取微分熵 (DE)、功率谱密度 (PSD)、Hjorth 参数等基于神经科学理论的时频域特征，训练 LightGBM 分类器，与 EEGNet 深度模型进行异构集成。

3. **严格的跨被试验证**：采用 GroupKFold 按被试划分交叉验证，杜绝同一被试数据同时出现在训练集和验证集中的信息泄露问题，确保评估结果反映真实的跨被试泛化能力。

2 作品方案设计及实现

2.1 技术路线概述

本方案的总体流程如图 2.1 所示，包含两条并行的技术路线：(1) 原始 EEG 信号经预处理后直接输入 EEGNet 深度模型进行端到端学习；(2) 预处理后的 EEG 提取 DE、PSD、Hjorth 参数等 390 维手工特征，由 LightGBM 分类器进行学习；最终将两条路线的预测结果进行软投票融合，得到最终分类输出。



图 2.1 总体技术路线流程图

2.2 数据预处理

竞赛数据包含 60 名被试（40 名健康对照 + 20 名抑郁症患者），每名被试在两种情绪状态（中性、积极）下分别记录了 50,000 时间点的 30 通道脑电信号，采样率为 250Hz。测试集包含 10 名被试（5 名健康对照 + 5 名抑郁症患者），每名被试包含 8 段情绪视频对应的脑电数据，共 20,000 时间点。DEAP 公开数据集包含 32 名被试，每名被试观看 40 段音乐视频后记录 32 通道脑电信号。

预处理流程如下：

1. **通道对齐**：DEAP 的 32 通道取前 30 通道与竞赛数据对齐。
2. **带通滤波**：采用 4 阶 Butterworth 滤波器进行 0.5–50Hz 带通滤波，去除直流漂移与高频噪声。
3. **滑动窗分段**：窗口长度 10 秒（2500 时间点），无重叠，匹配测试集的 8 段 × 10 秒视频分段格式。
4. **标签二值化**：DEAP 的连续 Valence 评分（1–9 分）以 5.0 为阈值转为二分类标签（Valence > 5 为积极，否则为中性）。
5. **Z-score 标准化**：每个 trial 内每通道分别进行零均值单位方差标准化。

2.3 手工特征与 LightGBM

从预处理后的 EEG trial 中提取三类、共 390 维经典特征：

1. **微分熵 (DE)**: 5 个频段 (δ : 1–4Hz, θ : 4–8Hz, α : 8–14Hz, β : 14–31Hz, γ : 31–50Hz) $\times$ 30 通道 = 150 维。DE = $\frac{1}{2} \log(2\pi e \sigma^2)$, 是 EEG 情绪识别中最有效的单类特征之一。
2. **功率谱密度 (PSD)**: 相同 5 频段 $\times$ 30 通道 = 150 维, 采用 Welch 方法估计各频段对数功率。
3. **Hjorth 参数**: Activity (信号方差)、Mobility (一阶导数与信号的标准差比)、Complexity (二阶导数与一阶导数的 Mobility 比) $\times$ 30 通道 = 90 维。

LightGBM 基于梯度提升决策树 (GBDT), 采用 leaf-wise 生长策略和 GOSS 采样。相比深度学习模型, 其优势在于: 参数数量少 (约两千个叶子节点) 天然防过拟合; 训练速度快; 自动输出特征重要性, 提供模型可解释性。

2.4 EEGNet 深度模型与迁移学习

2.4.1 EEGNet 架构

EEGNet[2] 是专为脑电信号设计的紧凑型卷积神经网络, 总参数量仅约 2,834 个。其核心结构包括: (1) 时间卷积层——用 64 个采样点的 1D 卷积核捕捉 EEG 时序特征; (2) 空间卷积层——采用深度可分离卷积对 30 个通道进行空间滤波; (3) 可分离卷积层——进一步提取高层时空特征。模型极少的参数量使其在小样本场景下具有天然的抗过拟合能力。

2.4.2 迁移学习策略

采用**预训练-微调**范式: 先在 DEAP 数据集上分别训练 EEGNet 和 TSception 至收敛 (EEGNet 最佳验证准确率 79.10%, TSception 最佳验证准确率 78.80%), 然后将除最后分类层外的全部权重迁移至竞赛数据模型, 在竞赛数据上进行微调。微调阶段使用较低的学习率 (1×10^{-4}) 和较强的权重衰减 (1×10^{-3}) 以防止灾难性遗忘。

同时也训练了 TSception 深度模型作为对比。TSception 由三个核心模块构成: 动态时间层采用多个不同尺度的 1D 卷积核捕捉多尺度时序动态特征; 非对称空间层分别对左半球、右半球和全脑电极进行 1D 空间卷积, 利用大脑情绪处理的不对称性; 高层融合层将上述特征拼接后经全连接层分类。模型总参数量约 311 万。

2.5 模型融合

采用**异构模型软投票融合策略**：EEGNet（深度学习）和 LightGBM（传统机器学习）对同一 trial 分别输出二分类概率，取两个概率向量的算术平均作为融合预测结果。两种模型基于完全不同的学习范式，其分类错误往往不重叠，融合后可实现互补。

3 作品测试方案及测试结果

3.1 测试方案

所有实验均采用 **5 折 GroupKFold** 按被试划分的交叉验证策略：将 60 名被试分为 5 组，每次以 48 名被试的数据训练、12 名被试的数据验证，确保同一被试的所有 trial 不会同时出现在训练集和验证集中——这是 EEG 跨被试评估的核心要求，回避此策略将导致数据泄露和虚假高分。

主要评价指标为分类准确率 (Accuracy)，报告 5 折平均值与标准差。

3.2 对比实验分析

各方法在 5 折 GroupKFold 交叉验证下的对比结果如表 3.1 所示。

表 3.1 各方法在 5 折 GroupKFold 交叉验证下的对比结果

方法	平均准确率	标准差	训练时间
TSception (从零训练)	53.35%	±0.84%	~2h
TSception (DEAP 预训练 + 微调)	53.78%	±0.84%	~1.5h
EEGNet (从零训练)	63.96%	±2.06%	~3min
EEGNet (DEAP 预训练 + 微调)	63.22%	±2.87%	~3min
LightGBM (手工特征)	62.19%	±1.91%	~4min
EEGNet + LightGBM 融合	64.26%	±1.45%	—

从实验结果可以发现：(1) 手工特征方法 (**LightGBM, 62.19%**) 显著优于从零训练的深度学习方法 (TSception 53.35%, EEGNet 63.96%)，表明在小样本 EEG 场景下注入领域知识的重要性；(2) EEGNet 仅 2,834 个参数却超越了 311 万参数的 TSception，证明过参数化模型在小样本数据上极易过拟合；(3) DEAP 预训练对两个模型均未带来实质性提升，反映出 DEAP 与竞赛数据之间的域鸿沟过大（采样率、刺激材料、采集范式均不同）；(4) EEGNet + LightGBM 异构融合达到最高 **64.26%**，证明深度学习与传统机器学习的错误模式具有互补性。




图 3.1 各模型 5 折 GroupKFold 交叉验证准确率对比

3.3 消融实验分析

为进一步验证各环节的贡献，设计了以下消融实验：

1. **预训练效果消融**：对比 TSception 和 EEGNet 有无 DEAP 预训练的表现差异。结果显示 DEAP 预训练仅带来约 0.4% 的提升（TSception: +0.43%; EEGNet: -0.74%），表明当源域和目标域分布差异较大时，迁移学习可能无法正面受益。
2. **模型规模对比**：将 2,834 参数的 EEGNet 与 3,111,106 参数的 TSception 直接对比，EEGNet 在小样本场景下高出约 10 个百分点，验证了轻量级模型的关键优势。
3. **特征组贡献分析**：LightGBM 的特征重要性排序（图 3.2）显示， γ 波段微分熵（DE_gamma）和 α 波段微分熵（DE_alpha）是最具区分力的特征，顶颞区（通道 18、12、17、22）是情绪分类最关键的电极位置。

3.4 训练过程分析

EEGNet 在 DEAP 预训练过程中仅用 1.8 分钟训练 19 个 epoch 即达到 79.10% 验证准确率，早停机制在验证损失不再下降时自动终止训练。微调阶段的训练曲线（图 3.4）显示，EEGNet 验证准确率在 16 个 epoch 左右趋于平稳，无明显过拟合现象；而 TSception 在微调过程中训练准确率持续上升但验证准确率停滞，表现出典型的过拟合特征。




图 3.2 LightGBM 特征重要性 Top-15




图 3.3 DEAP 预训练过程中 EEGNet 的训练与验证曲线




图 3.4 EEGNet 在竞赛数据上 5 折微调的训练与验证曲线

3.5 测试集推理

基于最终测试方案，使用 EEGNet + LightGBM 融合模型对 10 名测试被试的脑电数据进行推理预测。测试数据按官方描述，每名被试包含 8 段情绪视频对应的 10 秒脑电片段（共 80 个 trial），预测结果以规定模板格式输出为 submission.xlsx 文件。

4 总结

4.1 核心技术成果

本文针对小样本脑电情绪识别任务，提出并验证了一套完整的深度迁移学习与手工特征融合解决方案，主要成果包括：

1. **验证了小样本场景下手工特征方法的优势**：基于 390 维手工特征的 LightGBM 模型 (62.19%) 大幅超越了从零训练的深度学习基线 (TSception 53.35%)，表明注入神经科学先验知识对缓解过拟合至关重要。
2. **探索了跨数据集迁移学习的限制**：DEAP 预训练仅带来微弱提升 (约 0.4%)，揭示了源域与目标域之间范式差异对迁移效果的根本性制约。
3. **确认了轻量级模型的关键价值**：EEGNet 以仅 2,834 个参数在竞赛数据上达到 63.96%，而 311 万参数的 TSception 仅 53.35%，过参数化的危害得到充分验证。
4. **实现了异构模型融合**：EEGNet + LightGBM 软投票融合达到 64.26%，代表了本项目的最高水平。
5. **揭示了关键生物标志物**： γ 波和 α 波的微分熵被认为是情绪区分度最高的脑电特征，顶颞区域（通道 18、12、17、22）是情绪分类的关键电极位置。
6. **建立了完整可复现的工程管道**：从数据预处理、特征提取、模型训练、交叉验证到测试集推理的全流程代码均已开源。

4.2 展望

未来工作可从以下几个方向展开：(1) 引入 SEED、DREAMER 等更多公开数据集进行跨数据集预训练，增强模型对多样化 EEG 范式的泛化能力；(2) 采用 STAFNet、DAMGCN 等 2024 年最新架构并谨慎调参以适应小样本场景；(3) 使用 Grad-CAM、SHAP 等方法可视化模型关注的时间片段与脑区，为神经科学发现提供计算证据；(4) 探索自监督对比学习方法，降低模型对有标注训练数据量的依赖。

参考文献

- [1] Ding, Y. et al. (2023). TSception: Capturing Temporal Dynamics and Spatial Asymmetry from EEG for Emotion Recognition. *IEEE Transactions on Affective Computing*.
- [2] Lawhern, V.J. et al. (2018). EEGNet: A Compact Convolutional Neural Network for EEG-based Brain-Computer Interfaces. *Journal of Neural Engineering*.
- [3] Koelstra, S. et al. (2012). DEAP: A Database for Emotion Analysis Using Physiological Signals. *IEEE Transactions on Affective Computing*.
- [4] Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *NeurIPS*.
- [5] Hu, X. et al. (2024). STAFNet: An Adaptive Multi-Feature Learning Network via Spatiotemporal Fusion for EEG-based Emotion Recognition. *Frontiers in Neuroscience*.