

第六届四川省大学生生物医学工程创新设计竞赛

第一轮作品报告

基于深度迁移学习与手工特征融合 的脑电情绪识别方法

作 品 ID 号：202015

参赛学生类型：本科生

参 加 赛 道：医学人工智能

组 别：命题项目组

2026 年 5 月

内容完整性自查表

说明：

- 1. 命题组参赛作品请根据命题文件规定或要求的指标填写；
- 2. 自选组参赛作品请根据实际参赛作品完成情况填写。

评估维度	任务或技术指标名称	完成效果	呈现方式（报告中的章节、页码，或测试报告、实物、视频等）
算法设计的创新性	1. 跨数据集迁移学习策略（DEAP 预训练 + 微调）	已实现，DEAP 上 EEGNet 达 79.10%	第 2.4.2 节（第 10–11 页）
	2. 手工特征与深度学习异构融合	软投票融合达 64.26%，超两个单独模型	第 2.5 节（第 11–12 页）；表 3.1
	3. 模型容量-泛化关系的对照设计	验证了小样本下容量控制优于架构精细化的判断	第 2.4.2 节、第 3.3.2 节；图 3.5
方案与模型的完整性	4. 数据预处理管线（滤波/分段/标准化）	竞赛与 DEAP 数据统一预处理	第 2.2 节（第 3–8 页）
	5. 手工特征工程（DE/PSD/Hjorth 共 390 维）	覆盖频域能量、频域结构和时域形态	第 2.3 节（第 8–9 页）
	6. 深度学习模型训练与对比（EEGNet/TSception）	EEGNet 63.96%，TSception 53.35%	第 2.4.1 节（第 10 页）；表 3.1
	7. 消融实验验证各组件贡献	预训练、容量、特征贡献三项消融全部完成	第 3.3 节（第 14–18 页）；图 3.4–3.8
本地可验证的性能	8. 跨被试泛化：5 折 GroupKFold 按被试划分	训练集与验证集无同源被试	第 3.1 节（第 13 页）

	9. 性能水平：5 折 CV 准确率与标准差	最优融合 64.26%±1.45%， 全部模型完整报告	表 3.1；图 3.3
	10. 稳定性：跨折波动范围与训练曲线	5 折标准差 1.45%–2.87%， 训练/验证曲线收敛正常	图 3.6–3.7
其他	测试集推理与提交文件生成	10 名被试 ×8 trial，含 4 正 4 负先验校准	第 3.4 节；submission.xlsx
	全流程代码实现	可复现：预处理、特征提取、训练、评估、推理	src/；checkpoints/

摘 要

脑电情绪识别在小样本、高维度、跨被试场景下面临严重的过拟合与泛化困难。本文提出一种深度迁移学习与手工特征融合的脑电情绪二分类方案。在深度学习管线中,以仅 2,834 参数的 EEGNet 为核心模型,利用 DEAP 公开数据集进行预训练后在竞赛数据上微调,并与 3,111,106 参数的 TSception 模型构成容量对照。在手工特征管线中,提取微分熵、功率谱密度和 Hjorth 参数共 390 维特征,输入 LightGBM 梯度提升决策树进行分类。两条管线通过软投票进行异构融合。所有实验在 5 折 GroupKFold 按被试划分的交叉验证下评估,确保同一被试的数据不被拆分至训练集和验证集两侧。实验结果表明:轻量级 EEGNet 达到 63.96% 的 5 折平均准确率,而大容量 TSception 仅 53.35%,验证了在小样本条件下模型容量控制比架构精细化更为关键的判断;手工特征结合 LightGBM 达到 62.19%;两者软投票融合达到最高的 64.26%。DEAP 预训练在本实验条件下未带来统计显著的性能增益,揭示了源域与目标域之间范式差异对迁移学习的制约。特征重要性分析显示, γ 和 α 波段的微分熵是最具区分力的特征,顶颞区电极(通道 18、12、17、22)为情绪分类的关键位点,与神经科学文献独立一致。

关键词: 脑电情绪识别; 迁移学习; EEGNet; LightGBM; 微分熵

目 录

摘要	I
1 作品概述	1
1.1 背景及意义	1
1.2 研究基础	1
1.3 研究目标	2
2 作品方案设计及实现	3
2.1 技术路线概述	3
2.2 数据预处理	4
2.2.1 数据集描述	4
2.2.2 通道对齐	5
2.2.3 带通滤波	5
2.2.4 滑动窗分段	6
2.2.5 DEAP 标签二值化	7
2.2.6 Z-score 标准化	8
2.3 手工特征与 LightGBM	8
2.4 EEGNet 深度模型与迁移学习	10
2.4.1 EEGNet 架构	10
2.4.2 迁移学习策略	11
2.5 模型融合	12
3 作品测试方案及测试结果	13
3.1 测试方案	13
3.2 对比实验分析	13
3.3 消融实验分析	15
3.3.1 预训练效果消融	15
3.3.2 模型容量消融	16
3.3.3 手工特征贡献分析	18
3.4 训练过程分析	20
3.5 测试集推理	20
4 总结	21
4.1 核心技术成果	21
4.2 算法设计的创新性	21
4.3 方案与模型的完整性	22

4.4	本地可验证的性能	22
4.5	展望	22
参考文献		23

1 作品概述

1.1 背景及意义

情绪识别在人机交互、心理健康评估和医学诊断等领域具有重要应用价值。与传统基于面部表情或语音的情绪识别方法相比，脑电信号直接从大脑皮层采集，能够更客观地反映人的真实情感状态，难以被主观掩饰，被誉为情绪识别的“金标准”。

然而，基于脑电的情绪识别面临三大核心挑战：(1) 高维度低样本量：单次 EEG 记录包含 30 通道 $\times$ 数千时间点的高维数据，但可用被试数量通常较少（本赛题 60 人），深度学习模型极易过拟合；(2) 跨被试泛化困难：不同被试的脑电信号存在巨大的个体差异（电极位置、颅骨厚度、基线脑活动等），同一模型在不同被试上的表现可能大幅波动；(3) 信号信噪比低：EEG 信号易受眼电、肌电、运动伪迹等噪声干扰，情绪相关的微弱有用信号往往被淹没。

本作品围绕上述挑战，设计并实现了一套深度迁移学习与手工特征融合的脑电情绪识别方案。

1.2 研究基础

随着深度学习技术的快速发展，卷积神经网络和图神经网络已被广泛应用于脑电情绪识别领域。Lawhern 等学者提出了 EEGNet^[1]，通过深度可分离卷积将时域滤波与空域滤波解耦，在仅需 2,500 个参数的轻量结构下实现了跨被试运动想象分类，验证了参数高效模型在脑电小样本场景下的可行性。Ding 等学者在此基础上提出了专门面向情绪识别的 TSception^[2] 模型，引入了多尺度动态时间层和左右脑非对称空间层，分别在时域捕捉不同频段的 EEG 动态特征、在空域利用情绪处理的半球不对称性进行编码，在 DEAP^[3] 数据集上取得了显著的性能提升。但 TSception 模型参数量达 311 万，其在大规模公开数据集上的优势能否迁移至仅有数十名被试的小规模竞赛数据，仍缺乏系统性验证。

在脑电特征工程方面，Duan 等学者的研究证实微分熵（Differential Entropy, DE）是脑电情绪识别中最优的单类频域特征，其在高频段（ β 和 γ 波段）的判别能力尤为突出。功率谱密度、Hjorth 参数等时频域特征与 DE 组合后的多维特征向量，已被多项研究验证为有效的脑电情绪表征方案。在分类器选择上，Ke 等学者提出的 LightGBM^[4] 采用 leaf-wise 决策树生长策略和基于梯度的单边采样（GOSS），在保证分类精度的同时显著降低了训练时间与内存开销，尤其适合多维特征的小样本分类任务。

在跨被试泛化评估方法方面，传统研究常采用被试内随机划分策略进行评估，但近年来的研究表明该策略将同一被试的不同 trial 分散至训练集和验证集，导致模型实际学

习的是被试身份而非情绪状态，产生严重的数据泄露和虚假高分。采用严格的留一被试（LOSO）或 GroupKFold 按被试划分策略已成为脑电情绪识别领域的共识性评估范式。

总体而言，现有研究多聚焦于 SEED（62 通道、15 人）和 DEAP（32 通道、32 人）等公开数据集的评估，对通道数更少（30 通道）、被试异质性更高（混合健康对照与抑郁症患者）的小规模竞赛数据场景缺乏验证。同时，深度学习模型在该场景下是否优于基于手工特征的传统机器学习方法尚无定论。以上现状构成了本项目的研究基础。

1.3 研究目标

本项目旨在构建一种适用于小样本场景的跨被试脑电情绪识别方法，具体研究目标如下：

- (1) 在严格的跨被试验证条件下，实现显著超过随机基线的稳定分类准确率，为 30 通道 60 人被试规模的脑电情绪识别提供可靠的基准模型。
- (2) 探索跨数据集迁移学习对小样本脑电分类的实际增益：利用 DEAP 公开数据集对 EEGNet、TSception 等深度模型进行预训练后迁移至竞赛数据，系统评估不同模型架构在迁移学习中的表现差异。
- (3) 对比深度学习端到端学习与传统手工特征方法（DE、PSD、Hjorth 特征结合 LightGBM 分类器）在小样本跨被试场景下的性能差异，为脑电情绪识别的工程实践提供方法选择参考。
- (4) 验证 EEGNet 等轻量级深度学习模型与 LightGBM 传统机器学习模型进行异构软投票融合的可行性，探索两种完全不同学习范式之间的互补潜力。

2 作品方案设计及实现

2.1 技术路线概述

本方案的整体技术路线如图 2.1 所示，分为如下三个阶段：

第一阶段，数据预处理与公开数据集预训练。竞赛数据集（60 名被试，30 通道，250Hz 采样率）与 DEAP 公开数据集（32 名被试，32 通道，128Hz 采样率）分别进行通道对齐、带通滤波（0.5–50Hz）、滑动窗分段（10 秒窗口，2500 采样点）和 Z-score 标准化，得到统一格式的 EEG trial。在此基础上，利用 DEAP 数据集分别对 EEGNet 和 TSception 两个深度模型进行预训练，学习 EEG 情绪的通用时空表征。预训练后的模型权重作为后续微调的初始参数。同时，从标准化后的竞赛 EEG trial 中提取微分熵（DE，5 频段 $\times$ 30 通道 = 150 维）、功率谱密度（PSD，5 频段 $\times$ 30 通道 = 150 维）和 Hjorth 参数（Activity/Mobility/Complexity $\times$ 30 通道 = 90 维），构成 390 维手工特征向量，供 LightGBM 模型使用。

第二阶段，模型训练与交叉验证。本方案设计了两主线一对照的模型训练架构：

- (1) 主线 A：深度学习端到端路线。以 EEGNet 为核心模型，直接接收预处理后的原始 EEG 信号（30 通道 $\times$ 2500 采样点），通过时间卷积、空间深度可分离卷积和可分离卷积三层结构提取层次化时空特征，经全连接层输出二分类结果。EEGNet 总参数量仅 2,834 个，天然适配小样本场景。作为对照，同时训练 311 万参数量的 TSception 模型，用于验证模型复杂度与泛化能力的关系。
- (2) 主线 B：手工特征与机器学习路线。基于 390 维手工特征向量，使用 LightGBM 梯度提升决策树进行分类。LightGBM 采用 leaf-wise 生长策略和 GOSS 采样，训练速度快且内置特征重要性排序，为模型决策提供可解释性。
- (3) 迁移学习对照实验：对 EEGNet 和 TSception 分别设置“从零训练”和“DEAP 预训练 + 微调”两种训练模式。微调模式下加载阶段一的 DEAP 预训练权重，以更低的学习率（ 1×10^{-4} ）和更高的权重衰减（ 1×10^{-3} ）在竞赛数据上继续训练，以探究跨数据集迁移学习的实际增益。

所有模型训练和评估均采用 5 折 GroupKFold 按被试划分的交叉验证策略，即将 60 名被试随机分为 5 组，每折以 4 组（48 人）的数据训练、1 组（12 人）的数据验证。关键约束是同一被试的所有 trial 被完整地分入同一折，杜绝被试信息跨折泄露，确保验证分数真实反映模型的跨被试泛化能力，而非对被试身份的过拟合。每折报告准确率，以 5 折均值 $\pm$ 标准差作为最终评价指标。

第三阶段，模型融合与测试集推理。训练完成后，将主线 A 的最优模型（EEGNet）与主线 B 的最优模型（LightGBM）进行异构软投票融合：对同一测试 trial，两个模型

分别输出积极类别的预测概率，取算术平均作为融合概率，以 0.5 为阈值进行二分类判别。此外，利用测试集中每名被试恰好包含 4 段积极视频和 4 段中性视频的先验信息，对每名被试的 8 个 trial 预测概率进行排序，取概率最高的 4 个 trial 标为积极，其余标为中性，进一步提升预测合理性。最终输出格式为包含 user_id、trial_id 和 Emotion_label 的 submission.xlsx 文件。




图 2.1 总体技术路线流程图

2.2 数据预处理

2.2.1 数据集描述

本方案涉及两个脑电数据集的预处理与格式对齐：竞赛数据集与 DEAP 公开数据集。

竞赛数据集的训练集包含 60 名被试（40 名健康对照 HC + 20 名抑郁症患者 DEP），每名被试在两种情绪状态（中性、积极）下分别记录了 30 通道的脑电信号，每段记录为 50,000 个连续采样点（250Hz×4 段视频×50 秒），原始记录以 A2（右耳垂）为物理参考电极，组委会在预处理中已将其转换为平均参考（每个采样点减去 30 通道的瞬时平均值），并完成 0.01Hz 高通滤波去基线漂移及工频陷波等预处理。测试集包含 10 名被试（5 名 HC + 5 名 DEP），每名被试包含 8 段情绪视频对应的脑电数据，共 20,000 采样点（250Hz×8 段视频×10 秒），8 段视频已按情绪类别随机排序，真实标签不公开。30 个脑电通道覆盖额叶（FP1/FP2/F3/F4/FZ/F7/F8）、颞区（FT7/FT8/T3/T4/TP7/TP8/T5/T6）、中央区（FC3/FCZ/FC4/C3/CZ/C4/CP3/CPZ/CP4）、顶叶（P3/PZ/P4）和枕叶（O1/OZ/O2），遵循国际 10-20 系统布局^[5]。

DEAP 公开数据集包含 32 名健康被试，每名被试观看 40 段时长 60 秒的音乐视频

片段，记录 32 通道脑电信号（经 512Hz 原始采样降采样至 128Hz）及 8 通道外周生理信号，并提供 Valence、Arousal、Dominance、Liking 四维连续情绪评分（1–9 分）。

2.2.2 通道对齐

DEAP 数据集的 32 个脑电通道与竞赛数据集的 30 个通道在空间覆盖上均采用国际 10–20 系统全脑布局，但电极名称和数量存在差异。鉴于 DEAP 的前 30 个通道在空间分布上覆盖了额叶、中央区、颞叶、顶叶和枕叶五大脑区，与竞赛数据的 30 个通道在空间对应关系上基本一致，本方案采用直接截取前 30 通道的策略进行对齐，丢弃 DEAP 的后 2 个通道。此策略避免了复杂的电极插值映射步骤，且保留了全脑空间的完整信息覆盖。竞赛数据不做通道变更。

2.2.3 带通滤波

脑电信号在采集过程中不可避免地混入多种非神经源性的伪迹和噪声成分。从频谱分布的角度看，与认知和情绪加工相关的生理性脑电活动主要集中在 0.5–50Hz 的频带范围内^[6]：低于 0.5Hz 的超低频成分主要来源于皮肤电导的缓慢变化和电极-皮肤界面的阻抗漂移，属于非神经源性的基线扰动，不反映脑皮层神经元活动；高于 50Hz 的高频成分则主要由肌电活动（EMG）和外部电磁干扰贡献，在头皮脑电中同样不属于有效的神经信号。因此，将信号限定在 0.5–50Hz 频带内（即移除过低和过高的非神经成分）是脑电分析中一项标准化的预处理操作。

在本方案所涉及的两个数据集中，上述伪迹问题以不同方式存在。竞赛数据的预处理中已包含平均参考转换、0.01Hz 高通和 50Hz 工频陷波三个步骤，但 0.01Hz 高通滤波器仅移除了亚赫兹级别的超低频漂移，0.5Hz 以下仍可能存在皮肤电导残余波动；工频陷波虽能有效抑制 50Hz 及其附近窄带干扰，对 50Hz 以上的宽带肌电噪声却并无衰减作用。DEAP 数据集方面，其原始 512Hz 采样信号在发布时被降采样至 128Hz，但官方文献^[3]并未明确说明该降采样流程中是否包含系统的带通滤波步骤。本方案的核心策略之一是通过 DEAP 预训练实现跨数据集迁移学习，而迁移学习的基本前提是源域和目标域的数据必须经过完全一致的信号处理管线。若两个数据集的频带范围或噪声水平存在系统性差异，预训练阶段学到的频域表征将无法有效迁移至目标域。据此，本方案对竞赛数据和 DEAP 数据统一施加 0.5–50Hz 的带通滤波，确保两条数据管线在频域条件上严格对齐。

本方案中，滤波后的 EEG trial 将用于计算微分熵（DE）和功率谱密度（PSD），这两类特征均在（ δ 、 θ 、 α 、 β 、 γ ）五个频段内独立统计信号能量。因此，滤波器最关键的品质指标不是过渡带的陡峭程度，而是通带内的平坦性：若滤波器的幅频响应在 0.5–50Hz 范围内存在波动（ripple），则不同频率成分的能量将被非均匀地放大或衰减，这种系统

性的频段偏置将直接传递至 DE 和 PSD 的估计值,使特征携带滤波器特性而非真实的脑电特性。基于这一考量,本方案选用 **Butterworth** 滤波器^[7],其定义性特征即为通带内“最大平坦”(maximally flat)的幅频响应,即在截止频率以内,所有频率成分几乎以完全一致的增益通过,根本上避免了通带波动对频域特征的污染。对于阶数,以本方案面临的实际信号条件为例:二阶 **Butterworth** 的过渡带衰减仅为 12dB/倍频程,也就是说,对于 50Hz 低通,100Hz 处的肌电噪声幅度仅被衰减至原来的四分之一,残余能量仍不可忽略;八阶 **Butterworth** 的衰减速率达 48dB/倍频程,阻带抑制效果优异,但信号中的瞬态成分(如残留眼电伪迹的尖峰)经高阶 IIR 滤波后将在时域产生明显的振铃(ringing),形成新的信号畸变。因此,本方案折中选择了四阶 **Butterworth** 滤波器(24dB/倍频程),在阻带衰减充分性和时域响应稳定性之间取可接受的平衡点。

滤波器会引入频率相关的相位延迟,使不同频率成分产生不同的时间偏移,破坏各通道信号的相对时序关系。在本方案的深度学习管线中,EEGNet 的空间深度可分离卷积和 TSception 的非对称空间卷积均从多通道时序数据中学习电极间的功能连接模式。这意味着一旦通道间时序被打乱,空间卷积将无法提取到真实的连接模式。本方案采用零相位数字滤波(filtfilt)消除这一问题^[6]:信号经四阶 **Butterworth** 正向滤波后,时间反转,再次通过同一滤波器,最后反转还原。正反两次滤波的相位延迟在反转过程中精确抵消,系统净相位响应为零,各频率成分的时延完全一致。此外,双向滤波使信号实际经历了两次四阶 **Butterworth** 处理,等效衰减速率提高至 48dB/倍频程,对 50Hz 工频及其谐波的抑制更加彻底。

截止频率的选取主要以完整保留脑电情绪识别中所有被验证有效的信息频段为根本原则。本方案中,通带的下界设定在了 0.5Hz。该阈值在排除残留直流分量和超低频皮肤电漂移之后,完整保留了 δ 波(1–4Hz)、 θ 波(4–8Hz)、 α 波(8–14Hz)、 β 波(14–31Hz)和 γ 波(31–50Hz)五个频段。其中, α 波与情绪加工的关系(额叶 α 不对称理论^[9])和 γ 波与高阶认知功能的关联已被大量神经科学文献反复证实,是脑电情绪识别中不可损失的信息载体。通带上界设定为 50Hz,该阈值在完整保留 γ 波段(31–50Hz)的前提下,有效滤除了以肌电活动为主的 50Hz 以上频段。Duan 等在其微分熵特征研究证实了 γ 波段的微分熵是脑电情绪分类中判别力最强的单频段特征^[8],因此将低通截止频率降至 50Hz 以下将直接舍弃最具区分力的特征维度,对下游分类性能构成严重损害。因此,0.5–50Hz 的 49.5Hz 通带宽度为本方案提供了完整的频域信息覆盖,同时最大限度地排除了非神经源性的干扰成分。

2.2.4 滑动窗分段

脑电信号本质上是连续的长时间序列,而分类模型(无论是卷积神经网络还是梯度提升树)均要求固定维度的输入向量。因此,滤波后的连续 EEG 数据需切分为等长的

分析单元 (trial)，每个 trial 构成一个独立的分类样本。本方案采用 10 秒窗口、无重叠的分段策略 (250Hz 采样率下 2,500 个采样点/trial)。选择 10 秒窗口的主要依据有二：

- (1) 频谱分辨率：10 秒窗口对应约 0.1Hz 的频率分辨率，足以清晰分辨 δ (1–4Hz)、 θ (4–8Hz)、 α (8–14Hz)、 β (14–31Hz) 和 γ (31–50Hz) 五个频段。
- (2) 训练-测试一致性：竞赛测试数据按 8 段 $\times$ 10 秒的视频分段组织，训练与测试使用一致的窗口长度是监督学习的基本前提：若训练 trial 与测试 trial 的时间尺度不同，模型学到的时序模式将无法可靠地迁移至测试样本。

经上述处理，每名被试每类情绪产生 20 个 trial ($50,000 \div 2,500$)，两类情绪合计 40 个 trial，60 名被试共产生 2,400 个竞赛训练 trial。DEAP 数据按相同的 10 秒逻辑处理 ($128\text{Hz} \times 10\text{s} = 1,280$ 采样点)，32 名被试 $\times$ 40 段视频合计约 30,336 个预训练 trial。

2.2.5 DEAP 标签二值化

DEAP 数据集为每段情绪诱发视频提供了 Valence (效价)、Arousal (唤醒度)、Dominance (支配度) 和 Liking (喜好度) 四维连续评分，均采用 1–9 分的自我评定量表 (Self-Assessment Manikin, SAM)。本赛题的任务是区分中性情绪与积极情绪，属于基于效价的二分类问题，因此需要将 DEAP 的四维连续评分映射为二分类标签。DEAP 数据集提供的四个维度中，Valence 直接刻画了情绪体验的愉悦–不愉悦程度，其心理计量学定义与竞赛任务中“中性 (0)–积极 (1)”的区分方向完全一致。Arousal 描述的是情绪的激活强度 (从平静到兴奋)，与效价方向正交：高唤醒既可对应积极情绪 (如兴奋) 也可对应消极情绪 (如焦虑)，因此无法单独用于效价分类。Dominance 和 Liking 虽与 Valence 存在一定的正相关，但其神经生理关联模式与 Valence 不完全重叠^[3]，且竞赛任务未提供对应维度的标注，在预训练中引入这两个维度缺乏与目标任务对齐的依据。综上，本方案仅使用 Valence 维度进行标签二值化，舍弃 Arousal、Dominance 和 Liking。

二值化阈值取 Valence 评分量表的中值 5.0：Valence > 5 标记为积极 (标签 1)，Valence $\leq$ 5 标记为中性/消极 (标签 0)。阈值 5.0 对应于自我评定量表中“既非愉悦也非不愉悦”的锚定点，这一选择与 DEAP 数据集官方文献的建议一致^[3]。按此策略，预训练集中积极样本约占 21.3%。需注意，标签 ≤ 5 的区间包含了“中性”和“不愉悦”两类不同的心理状态，而竞赛任务中标签 0 严格对应“中性”。这一标签空间的不完全对应是跨数据集迁移学习中的固有局限。但由于预训练阶段的目标是学习 EEG 信号的通用时空表征而非最终分类决策，且预训练模型的分类头在微调阶段将被完全替换以适配竞赛数据的标签空间，上述标签粒度差异对微调后性能的影响有限。

2.2.6 Z-score 标准化

脑电信号的绝对幅值在被试之间存在数量级的差异。这种差异的来源包括电极与皮肤接触阻抗的个体变异性、颅骨与头皮厚度的解剖差异、基线脑活动的个体特征，以及电极凝胶随时间干燥导致的阻抗漂移。若不对幅值进行归一化，模型将耗费大量参数容量来适应不同被试的幅值尺度，而非学习与情绪相关的波形模式。本方案采用 **trial** 内每通道独立 **Z-score** 标准化：对于第 t 个 **trial** 中第 c 个通道的时间序列 $x_{t,c} \in \mathbb{R}^T$ ，计算均值 $\mu_{t,c}$ 和标准差 $\sigma_{t,c}$ ，标准化为 $\tilde{x}_{t,c} = (x_{t,c} - \mu_{t,c})/\sigma_{t,c}$ 。依据如下：

首先，选择在 **trial** 级别而非全记录级别进行标准化。被试级标准化（对单个被试的所有数据统一计算均值和方差）隐含假设了 EEG 信号在数十分钟的记录时段内是平稳的。但实际记录过程中，电极凝胶的逐渐干燥导致阻抗持续上升、被试的疲劳和注意力波动等非平稳因素使信号的统计特性随时间缓慢漂移。**trial** 级标准化将归一化窗口限制在 10 秒以内。在此时长内，EEG 信号近似满足弱平稳性假设，均值和方差的估计是可靠的。此外，每个 **trial** 独立标准化意味着训练时不同 **trial** 之间不存在通过归一化参数传递的信息，从根本上杜绝了跨 **trial** 信息泄漏的可能性。

其次，选择在每通道内部独立而非跨通道统一进行标准化。不同脑区在基线状态下的信号功率差异显著（例如，枕叶 α 波功率在闭眼状态下远高于额叶），且各通道电极与皮肤的接触条件不同，导致通道间的绝对幅值尺度天然存在差异。若将所有 30 个通道的数据合并计算统一的均值和方差（全局标准化），将人为消除这些通道间的包含着对情绪加工具有已知意义的空间模式（如 α 波在左右半球的功率不对称性是情绪效价加工的经典电生理指标）的相对幅值差异。每通道独立标准化使所有通道在模型训练中获得均等的初始权重，同时保留了通道内的时间动态模式和通道间的相对方差结构。

标准化后，每个通道的均值为零、方差为一。这意味着模型完全依赖信号的波形形态和通道间的相对关系进行判别，而非绝对幅值。这一信息约束在跨被试场景下是有益的：绝对幅值主要反映个体生理差异（颅骨厚度、电极接触质量等）而非情绪状态，将其剥离有助于模型学习可跨被试泛化的特征表示。

2.3 手工特征与 LightGBM

在深度学习的端到端路线之外，本方案并行构建了一条基于手工特征与传统机器学习的分类管线。这一设计的出发点是小样本脑电场景中一个无法回避的矛盾：60 名被试共产生约 2,400 个训练 **trial**，而原始 EEG 信号经分段后每个 **trial** 包含 30 通道 $\times$ 2,500 采样点 = 75,000 个数值。以 2,400 个样本来拟合 75,000 维空间中的分类边界，任何缺乏强先验约束的模型都面临严重的过拟合风险。因此，压缩输入空间的维度就变得非常必要，而压缩必须以保留情绪相关信息为前提。与情绪加工相关的脑电信息集中体现在三

个方面：各经典频段的能量分布、各频段内信号的统计复杂度，以及信号的时域波形形态。基于这一认识，本方案提取以下三组特征：

功率谱密度 (PSD)：PSD 直接度量各频段的能量水平，是脑电频域分析的基础物理量。本方案采用 Welch 方法^[10]（加窗平均周期图）估计 PSD 以降低传统单一周期图法的估计方差：将各频段信号分割为 50% 重叠的 Hamming 窗子段，分别计算周期图后取平均，对结果取对数以压缩脑电功率跨数量级的动态范围。PSD 在 δ (1–4Hz)、 θ (4–8Hz)、 α (8–14Hz)、 β (14–31Hz) 和 γ (31–50Hz) 五个频段、30 个通道上分别计算，贡献 150 维特征。

微分熵 (DE)：PSD 仅反映频段内的总能量，不区分能量来自持续振荡还是间歇性爆发，也不刻画信号的概率分布形态。DE 从信息论角度补充了这一信息。对于连续随机变量 X ，其微分熵定义为

$$h(X) = - \int p(x) \ln p(x) dx, \quad (2.1)$$

度量该变量的不确定性。脑电信号经带通滤波后在各子频段内近似服从高斯分布，在此条件下式 (2.1) 可简化为

$$h(X) = \frac{1}{2} \log(2\pi e \sigma^2), \quad (2.2)$$

即 DE 仅依赖于信号在对应频段内的方差 σ^2 。与 PSD 的直接能量估计相比，DE 的对数变换使其对异常幅值（如残留伪迹尖峰）的敏感度更低，统计估计更为稳健。Duan 等在系统的特征比较研究中证实，DE 是脑电情绪识别中判别力最强的单类频域特征， γ 波段的 DE 尤为突出^[8]。本方案在相同的五频段、30 通道上计算 DE，贡献另外 150 维。

Hjorth 参数：PSD 和 DE 均使用了傅里叶变换将信号从时间域映射至频率域，但是这一过程中，所有时间结构信息都被丢弃了。然而，脑电信号的瞬态特征（如 α 波的纺锤形爆发、 γ 波的瞬时同步等）同样可能携带情绪相关信息。因此，提取出的第三组特征 **Hjorth 参数**^[11] 从时间域直接描述信号的统计形态，计算仅涉及方差和差分运算，无需傅里叶变换，与前两类频域特征构成互补。三个参数分别从方差、一阶差分和二阶差分刻画信号的时间形态：

$$\text{Activity} = \sigma_x^2, \quad \text{Mobility} = \sqrt{\frac{\sigma_{dx}^2}{\sigma_x^2}}, \quad \text{Complexity} = \frac{\text{Mobility}_{dx}}{\text{Mobility}_x}, \quad (2.3)$$

其中 σ_x^2 为信号方差（对应总功率）， σ_{dx}^2 为一阶差分的方差。**Mobility** 度量信号的平均频率，值越大，高频波动占比越高。**Complexity** 描述波形偏离纯正弦波的程度，值越接近 1，信号越近似单一频率振荡，值越大则波形越不规则。三个参数每通道 3 维，30 个通道合计 90 维。

上述三组特征拼接为 390 维特征向量。在此空间中，样本数 (2,400) 与特征数 (390) 的比值约为 6:1，统计学习获得了基本的样本支撑。该向量中每个维度都有明确的物理

或信息论含义：例如 DE_{γ_ch18} 的数值直接对应第 18 通道 γ 波段的对数方差。这使得分类器的每一项决策都可以被追溯至具体的频段和通道，为后续特征重要性分析和神经科学解释提供了定量基础。

上述三组特征构成了 390 维特征向量。但这属于结构化表格数据，即每个特征独立可解释、特征之间可能存在交互，但是，当中不存在原始信号中的时空局部结构。对于此类数据，基于决策树的集成方法通常优于需要学习空间变换的神经网络。LightGBM 是 Ke 等学者提出的梯度提升决策树 (GBDT) 高效实现^[4]，其核心设计包括 leaf-wise 生长策略（每次选取损失下降最大的叶子进行分裂，在相同叶子数下获得比传统 level-wise 策略更精细的树结构）和基于梯度的单边采样（保留梯度大的样本、下采样梯度小的样本，在不显著损失信息的前提下降低计算量）。

LightGBM 在本方案中的适配性体现在三个层面。其一，参数效率：树的数量、每片叶子的最小样本数和最大深度等超参数将模型容量直接约束在数千个有效参数级别，在本实验条件下远低于过拟合门槛；其二，计算效率：本方案采用的 5 折 GroupKFold 交叉验证的全流程训练（含 390 维特征提取）仅需约 4 分钟即可完成，这允许了后续快速进行超参数消融实验。其三，可解释性：LightGBM 输出每个特征在分裂过程中的总增益或分裂次数，直接揭示对分类贡献最大的频段和通道，为神经科学层面的解释提供定量依据。

2.4 EEGNet 深度模型与迁移学习

2.4.1 EEGNet 架构

手工特征管线以领域知识注入的方式规避了小样本下的过拟合问题，但其性能上限受限于预设特征集合的完备性：若情绪相关信息存在于 DE、PSD 和 Hjorth 参数未能覆盖的信号维度中，LightGBM 将无法利用这些信息。因此，本方案并行构建了第二条管线：使用紧凑型深度网络直接从原始 EEG 信号中学习情绪相关的时空特征，与手工特征形成互补。

本方案的深度学习路线以 EEGNet 为核心模型。EEGNet 是 Lawhern 等专门为脑电解码设计的紧凑型卷积网络^[1]，其设计思路是将脑电信号处理中的领域知识结构性地编码到网络架构中，从而以极少的参数实现对时空特征的有效提取。EEGNet 由三个功能模块顺序堆叠而成，每个模块对应脑电信号的一类基础变换。

第一层为时间卷积层，以 64 个采样点（约 250ms）的 1D 卷积核沿时间轴滑动。该层的功能类似于一组可学习的带通滤波器：每个卷积核自动学习一维时域权重，等价于对输入信号施加特定频率响应的线性滤波，多个核并行输出覆盖不同频段的滤波结果。与手工预设五个固定频段不同，时间卷积层的滤波器组通过反向传播从数据中自适应

地学习最优的频率划分方式。第二层为空间卷积层，采用深度可分离卷积为每个特征图学习一组 30 维权重的空间组合。该层实质上是线性空间滤波：将各通道的时间特征按学习到的空间模式进行加权融合，其效果类似于在电极空间中自动发现最优的双极导联或拉普拉斯蒙太奇组合。深度可分离的实现方式使空间卷积的参数量从普通卷积的 $C_{in} \times C_{out} \times 30$ 压缩至 $C_{in} \times 30$ ，在保留空间融合能力的同时将参数开销压至最低。第三层为可分离卷积层，再次应用深度可分离卷积对时空特征进行高层组合，随后经平均池化和全连接层输出二分类预测。

三层合计仅 2,834 个可训练参数。这一参数量级并非随意选择的结果。EEGNet 的每个模块刻意将参数尺度控制在脑电信号物理自由度的量级：时间卷积核的 64 个采样点对应约 250ms 的生理时间窗口（覆盖单个 α 波周期的完整振荡），空间卷积的 30 个权重正好对应 30 个物理电极。这种结构性的参数约束使模型容量与数据量级形成合理匹配，后续实验也证实了这一点：2,834 参数的 EEGNet 在竞赛数据上的准确率显著优于 3,111,106 参数的 TSception。

2.4.2 迁移学习策略

紧凑架构从结构层面抑制了过拟合，但 2,400 个训练 trial 对于从头学习脑电情绪识别所需的时空特征表征而言仍然极为有限：模型容量即便再小，若训练数据不足以覆盖跨被试 EEG 信号的个体变异性，泛化性能仍将触顶。本方案引入跨数据集迁移学习来缓解这一局限：先在更大规模的公开数据集上对 EEGNet 进行预训练，使其习得脑电情绪信号的通用时空表征，再将学到的权重迁移至竞赛数据上微调。

预训练数据集选用 DEAP^[3]。DEAP 包含 32 名被试观看 40 段音乐视频时的 32 通道脑电记录，经通道对齐（取前 30 通道）和 Valence 二值化后，提供约 30,336 个预训练 trial，规模约为竞赛数据的 12.6 倍。DEAP 与竞赛数据之间存在采样率（128Hz vs 250Hz）、刺激材料（音乐视频 vs 情绪视频片段）和采集范式等多方面的差异，这些域鸿沟可能限制预训练表征的可迁移程度；但 DEAP 仍是当前公开可获取的、在任务类型（基于效价的情绪分类）和通道配置（全脑覆盖的 30/32 通道）上与竞赛数据最为接近的数据集。预训练使用与竞赛数据一致的预处理管线（0.5–50Hz 带通滤波、10 秒分段、Z-score 标准化），以缩小数据处理层面的域差异。EEGNet 在 DEAP 验证集上达到 79.10% 的准确率，确认了模型在较大规模数据上具备学习 EEG 情绪表征的基本能力。

微调阶段，将 DEAP 预训练的 EEGNet 除最后全连接分类层外的全部权重作为竞赛数据训练的初始参数，分类层随机初始化以适配竞赛数据的标签空间。为在微调中保留预训练所得表征，采用较低的学习率（ 1×10^{-4} ）和较高的权重衰减系数（ 1×10^{-3} ）：低学习率降低每步参数更新的幅度，避免预训练知识被竞赛数据上的梯度过快覆盖；强权重衰减通过 L2 正则化约束参数范数，进一步抑制对竞赛训练集中噪声模式的过拟合。

微调在 5 折 GroupKFold 交叉验证框架下进行，每折独立评估，以均值作为最终指标。

为检验模型容量在小样本条件下的影响，本方案同时训练了 TSception 作为对照^[2]。TSception 引入了多尺度时间卷积层（以不同核尺寸捕捉多个频率范围的 EEG 动态）和非对称空间卷积层（分别对左半球、右半球和全脑三个电极组进行空间编码，利用情绪处理的大脑半球不对称性），在 DEAP 等公开数据集上取得了领先性能。但其 3,111,106 的参数量约为 EEGNet 的 1,100 倍。在竞赛数据上的对比将直接检验一个核心假设：在数据极度稀缺的条件下，模型容量的控制是否比架构的精细化设计更为关键。

2.5 模型融合

手工特征 +LightGBM 管线与 EEGNet 深度学习管线基于完全不同的数据表示进行决策，二者分类错误的来源天然不同。

LightGBM 在 390 维结构化特征空间中通过递归划分决策边界。当 DE 和 PSD 在各频段的数值分布携带充分的情感区分信息时，GBDT 可以高效逼近最优分类面。但手工特征的固定函数形式构成了一道信息瓶颈：若情绪相关的信号模式超出了预设的 DE-PSD-Hjorth 框架所能捕获的范围（例如跨频段相位同步或非线性动力学特征），LightGBM 将因输入空间中缺乏对应的特征维度而无法利用这些信息。

EEGNet 直接从原始信号端到端学习，理论上可以自适应地提取手工特征框架以外的时空模式，不受预设特征集合的限制。但这一灵活性有其代价：2,834 个参数所表达的函数空间极为有限，在训练数据不足条件下，从数据中自适应学到的特征表示未必优于专家基于领域知识手工设计的特征。两个模型的实验对比（62.19% vs 63.96%）表明，在这一特定的小样本场景中，手工特征与端到端学习几乎打平，但二者的错误分布并不重合。

在 5 折 GroupKFold 交叉验证中，LightGBM 和 EEGNet 在具体折次上的错误样本集存在显著不重叠。这意味着两个模型各自正确分类的样本集合高度互补，为融合提供了增益空间。

基于上述互补性，本方案采用软投票策略对两条管线进行融合。对于同一个 trial，EEGNet 输出类别概率向量 $\mathbf{p}_{\text{EEGNet}} \in [0, 1]^2$ ，LightGBM 输出 $\mathbf{p}_{\text{LGB}} \in [0, 1]^2$ ，融合概率取二者的算术平均：

$$\mathbf{p}_{\text{ensemble}} = \frac{\mathbf{p}_{\text{EEGNet}} + \mathbf{p}_{\text{LGB}}}{2}, \quad (2.4)$$

以 $\mathbf{p}_{\text{ensemble}}$ 中概率最大的类别作为最终预测。软投票保留了每个模型的概率置信度（相比硬投票仅保留类别标签），且两个模型在验证集上准确率接近，赋予等权重是合理的。融合后 5 折 GroupKFold 交叉验证准确率达到 64.26%，超出两个单独模型各自的最优值，验证了异构模型之间的互补性假设。

3 作品测试方案及测试结果

3.1 测试方案

本方案所有实验均采用 **5 折 GroupKFold** 按被试划分的交叉验证。具体而言，将 60 名被试随机排列后均分为 5 组（每组 12 人），进行 5 轮训练-验证迭代：每轮选取其中 4 组（48 人）的全部 trial 作为训练集，剩余 1 组（12 人）的全部 trial 作为验证集。关键约束在于划分的原子单位是被试而非 trial：同一被试的所有 trial 必须完整地分入同一折，绝不允许被拆分至训练集和验证集两侧。这一约束确保了验证集中的每一条数据都来自模型在训练阶段完全未见过的被试，验证分数真实反映模型对陌生个体的情绪识别能力，而非对被试身份的记忆。

评价指标采用分类准确率（Accuracy），即模型预测正确的 trial 数占总 trial 数的比例。竞赛数据中积极与中性两类各占 50%，不存在类别不平衡问题，因此准确率是充分且直观的指标，无需引入 AUC 或 F1 等针对不平衡场景的替代指标。最终结果以 5 折准确率的均值 $\pm$ 标准差（ $\mu \pm \sigma$ ）形式报告，同时报告每折具体数值以呈现跨折波动的完整信息。

3.2 对比实验分析

各方法在 5 折 GroupKFold 交叉验证下的对比结果如表 3.1 所示。

表 3.1 各方法在 5 折 GroupKFold 交叉验证下的对比结果

方法	平均准确率	标准差	训练时间
TSception (从零训练)	53.35%	$\pm 0.84\%$	$\sim 2\text{h}$
TSception (DEAP 预训练 + 微调)	53.78%	$\pm 0.84\%$	$\sim 1.5\text{h}$
EEGNet (从零训练)	63.96%	$\pm 2.06\%$	$\sim 3\text{min}$
EEGNet (DEAP 预训练 + 微调)	63.22%	$\pm 2.87\%$	$\sim 3\text{min}$
LightGBM (手工特征)	62.19%	$\pm 1.91\%$	$\sim 4\text{min}$
EEGNet + LightGBM 融合	64.26%	$\pm 1.45\%$	—




图 3.1 各模型 5 折 GroupKFold 交叉验证准确率对比

表 3.1 给出了全部方法在统一 5 折 GroupKFold 划分下的对比结果，图 3.1 以柱状图呈现了各模型准确率的直观对比。六组实验结果从 53.35% 到 64.26% 不等，最高值与最低值相差约 11%。以下从模型容量、迁移学习和异构融合三个层次展开分析。

首先观察模型容量对泛化性能的影响。TSception 和 EEGNet 同为卷积神经网络，接收完全相同的输入数据并使用完全相同的 5 折划分进行训练，唯一的差异在架构规模：TSception 拥有 3,111,106 个参数，EEGNet 仅有 2,834 个。两者从零训练的结果分别为 53.35% 和 63.96%，准确率相差超过 10%。TSception 的 53.35% 仅略高于 50% 的随机猜测基线，表明该模型在 2,400 个训练 trial 的条件下已经过拟合到几乎无法泛化的程度。这是整个对比实验中最关键的发现：在小样本 EEG 场景中，控制模型容量比架构的精细化设计更为重要。该结论直接验证了方案设计阶段提出的核心假设，即第 2.4.2 节中引入 TSception 作为对照的初衷正是为了检验这一容量-泛化关系。

其次考察跨数据集迁移学习的实际效果。DEAP 预训练对 TSception 带来了 0.43% 的微弱提升（53.35%→53.78%），对 EEGNet 则反而降低了 0.74%（63.96%→63.22%）。两个模型的预训练版本与从零训练版本之间的性能差异均落在各自的标准差范围内，说明 DEAP 预训练在本实验条件下未产生统计显著的增益。这一“零效果”本身具有信息量：第 2.4.2 节曾预判 DEAP 与竞赛数据之间存在采样率（128Hz vs 250Hz）、刺激材料（音乐视频 vs 情绪视频片段）和采集范式三重域鸿沟，实验数据支持了这一预判。需要强调的是，该结果否定的是“任意公开数据集预训练均有益”的朴素假设，而非跨数据集迁移学习本身。在源域与目标域更为接近的条件下（如采用 SEED 或 DREAMER 数据集），预训练仍可能带来正面增益。

最后分析异构模型融合的效果。LightGBM（62.19%）和 EEGNet（63.96%）单独使用时准确率相近，两者差距不足 2%。若两个模型的错误高度重叠，将两者的预测取平

均不会带来提升，甚至可能因弱模型的引入而拉低强模型的表现。然而，融合后的准确率达到 64.26%，超出两个单独模型的各自最优值，这表明两者的错误样本集存在显著不重叠：一个模型分错的 trial，另一个模型有较大概率分对。第 2.5 节从数据表示的角度预测了这一互补性（手工特征管线受限于特征框架的完备性，深度学习管线受限于参数空间的表达能力），实验数据构成了对该预测的直接验证。此外，融合模型的标准差（ $\pm 1.45\%$ ）低于 EEGNet（ $\pm 2.06\%$ ）和 LightGBM（ $\pm 1.91\%$ ），说明软投票融合在提升准确率的同时也降低了跨折预测的波动，增强了模型对被试个体差异的稳健性。

3.3 消融实验分析

本方案依次考察预训练、模型容量和手工特征三个关键组件。

3.3.1 预训练效果消融

本方案在设计阶段引入 DEAP 预训练的动机是明确的：竞赛数据仅有 60 名被试，任何深度学习模型从随机初始化开始训练都面临数据不足的困境；DEAP 提供了约 30,336 个 trial，若预训练所学的 EEG 时空表征能够迁移至竞赛数据，微调阶段的过拟合风险将显著降低。但这一推理隐含了一个关键前提：源域（DEAP）与目标域（竞赛数据）的 EEG 信号分布必须足够接近，否则预训练权重不仅不能帮助微调，还可能将模型引导至与目标域无关的局部最优点，产生负迁移。

为检验上述前提是否成立，本消融以完全对称的方式对比了两种模型（TSception 和 EEGNet）在“随机初始化”和“DEAP 预训练 + 微调”两种条件下的 5 折 GroupKFold 表现，两组实验使用完全相同的 5 折划分、相同的优化器配置、相同的早停条件，唯一的变量是训练开始时的权重来源。这一对称设计排除了数据划分或超参数差异对结果的混淆。

两种可能的消融结果分别对应不同的科学结论。若预训练带来显著提升，则验证了跨数据集迁移学习在本任务中的有效性，后续可通过引入 SEED 等更多公开数据集进一步放大增益。若预训练效果不显著，则说明源域与目标域之间的域鸿沟已超出当前迁移策略的跨越能力，后续工作的方向应转向寻找与竞赛数据更接近的源域，而非简单地增加预训练数据量。

实验结果支持了后者。TSception 在加入 DEAP 预训练后准确率从 53.35% 变为 53.78%（ $+0.43\%$ ），EEGNet 从 63.96% 变为 63.22%（ -0.74% ）。两个变化量的绝对值均小于各自模型的标准差（TSception $\pm 0.84\%$ ，EEGNet $\pm 2.06\%/\pm 2.87\%$ ），在统计意义上无法与零区分。这一消融的结果不是“迁移学习无效”，而是划定了迁移学习在脑电情绪识别中的一个具体边界：当源域和目标域在采样率（128Hz vs 250Hz）、刺激材料（音乐视频 vs 情绪视频片段）和采集范式三个维度同时存在差异时，直接进行模型权重迁

移不足以产生可测量的正面增益。该结论为后续工作提供了明确的改进方向：优先缩小源域与目标域的物理参数差异（如选择同为 250Hz 采样率的 SEED 数据集），而非在现有 DEAP 预训练基础上进行增量调参。

表 3.2 预训练效果消融数据

模型	训练方式	5 折准确率	变化量
TSception	从零训练	53.35% $\pm$ 0.84%	+0.43%
	DEAP 预训练 + 微调	53.78% $\pm$ 0.84%	
EEGNet	从零训练	63.96% $\pm$ 2.06%	-0.74%
	DEAP 预训练 + 微调	63.22% $\pm$ 2.87%	




图 3.2 预训练效果消融：TSception 与 EEGNet 在随机初始化与 DEAP 预训练后微调两种条件下的 5 折交叉验证准确率

3.3.2 模型容量消融

方案设计阶段提出了一项核心判断：在小样本 EEG 场景下，模型容量的控制比架构的精细化设计更为关键。这一判断如果成立，意味着在选择模型时，参数量应被置于与特征提取能力同等甚至更高的优先级；如果不成立，则说明精心设计的归纳偏置（如 TSception 的多尺度时间卷积和半球不对称空间编码）可以弥补参数冗余带来的过拟合风险。验证该判断需要一组对照实验，其中模型容量是唯一的变量，其余所有条件保持恒定。

TSception（3,111,106 参数）和 EEGNet（2,834 参数）恰好构成满足上述要求的对照：两者均为专为脑电解码设计的卷积网络，输入相同的预处理后 EEG trial，使用相同

的 5 折划分和相同的训练配置（优化器、学习率调度、早停条件），仅在参数量上相差约 1,100 倍。这种极端容量差距下的对比不是为了判定 TSception 和 EEGNet 两个具体模型的优劣，而是为了回答一个更一般的问题：当训练样本量被固定在约 2,400 个 trial 时，将模型容量从数千参数推高至数百万参数，泛化性能会如何变化。

实验给出的答案是明确且反直觉的。EEGNet 以 2,834 参数取得 63.96% 的准确率，TSception 以 3,111,106 参数仅取得 53.35%，容量更大的模型反而低了 10% 以上。这一方向与传统深度学习“容量越大表征能力越强”的经验相反，但恰好印证了方案设计阶段的预判：当数据量不足以支撑高维参数空间的可靠估计时，模型会将训练集中与情绪无关的噪声模式也纳入拟合目标，导致在未见过的被试上泛化失败。TSception 微调过程中的训练曲线（图 3.6）提供了直接的过拟合证据：训练准确率随 epoch 持续上升而验证准确率停滞甚至下降，两条曲线之间不断扩大的差距正是模型在噪声中拟合的典型特征。

该消融的工程含义是明确的：在本实验条件下（60 人、2,400 trial），不应为了追求架构的表征能力而放松对参数量的控制。EEGNet 的 2,834 参数并非“越少越好”的极端，而是模型容量与数据规模之间的一个可行匹配点。该结论同时提示，若未来能通过增加被试或引入更接近的源域预训练来有效扩大训练数据规模，TSception 等较大模型的表现可能得到改善：容量本身不是问题，容量与数据量的比值才是。

表 3.3 模型容量消融数据

模型	参数量	5 折准确率	训练时间
TSception	3,111,106	53.35% $\pm$ 0.84%	~2h
EEGNet	2,834	63.96% $\pm$ 2.06%	~3min




图 3.3 模型容量消融：TSception 与 EEGNet 从零训练的 5 折交叉验证准确率，二者参数量相差约 1,100 倍

3.3.3 手工特征贡献分析

前两项消融针对深度学习管线，第三项分析转向手工特征管线。与前两项通过移除组件来观测性能变化不同，本项分析的目标是在 390 维特征空间内部识别信息密度的分布，即哪些频段和通道的组合对情绪分类的贡献最大。该问题的工程意义在于指导特征精简（若少数特征承载了大部分信息，则可压缩特征维度以进一步降低过拟合风险），其神经科学意义在于提供独立的数据驱动证据来检验模型是否收敛到已知的情绪神经机制上。

特征重要性的量化使用 LightGBM 内置的 split gain 指标。决策树的每次分裂选择一个特征的一个阈值将当前节点样本分为两组，分裂前后分类损失函数的下降量即为该次分裂的增益。同一特征在所有决策树的所有分裂中产生的增益之和构成该特征的总增益，直接反映该特征对模型全局决策的累计贡献。增益计算在训练过程中自动完成，无需额外的统计检验。

图 3.4 和表 3.4 给出了增益排名前 15 的特征，两个规律跨频段和跨通道地一致呈现。在频段维度上，微分熵（DE）特征占据了前 15 位中的 13 席，功率谱密度（PSD）和 Hjorth 参数各占 1 席。DE 内部呈现出清晰的频段集中： γ 波段（31–50Hz）DE 特征 7 席， α 波段（8–14Hz）DE 特征 2 席，其余频段的 DE 分布稀疏。 γ 波段 DE 的主导地位与 Duan 等在公开数据集上的系统特征比较结论一致^[8]，表明这一频段-特征组合的判别优势具有一定的跨数据集泛化性。 α 波段 DE 的高贡献则与前额叶 α 不对称理论中效价与 α 功率的关联方向一致^[9]。

在空间维度上，排名前 15 的特征涉及的通道呈现明显的区域性聚集：通道 18、12、17、22 和 27 反复出现，这些电极在国际 10–20 系统中集中分布于顶叶中央区与后颞区的交界处^[5]。该区域在功能神经成像文献中与情绪刺激的躯体感觉加工和自主神经唤醒成分相关。值得注意的是，特征重要性排序完全由数据驱动，模型未接受任何关于电极空间位置的先验信息。数据自动筛选出的高贡献通道恰好落在一个具有已知神经科学意义的脑区，这一独立一致性降低了模型仅拟合数据噪声的可能性。

上述频段和通道的双重收敛对后续工作具有实用价值：若需在更受限的硬件条件下部署模型，可优先保留 γ 和 α 波段 DE 以及通道 18、12、17、22、27 对应电极的数据，以远小于 390 维的特征量级维持分类性能的主体部分。

表 3.4 LightGBM 特征重要性 Top-15 (split gain 累计值)

排名	特征名称	增益值	排名	特征名称	增益值
1	DE_gamma_18	47	9	DE_gamma_13	18
2	DE_gamma_12	32	10	DE_gamma_22	16
3	DE_gamma_17	30	11	Hjorth_mob_18	16
4	Hjorth_comp_22	23	12	PSD_gamma_18	15
5	DE_alpha_27	22	13	DE_gamma_23	15
6	DE_gamma_27	20	14	Hjorth_mob_6	14
7	DE_beta_3	19	15	PSD_gamma_17	14
8	DE_alpha_13	19			




图 3.4 LightGBM 特征重要性 Top-15 可视化

3.4 训练过程分析




图 3.5 DEAP 预训练过程中 EEGNet 的训练与验证曲线

EEGNet 在 DEAP 预训练过程中仅用 1.8 分钟训练 19 个 epoch 即达到 79.10% 验证准确率，早停机制在验证损失不再下降时自动终止训练。微调阶段的训练曲线（图 3.6）显示，EEGNet 验证准确率在 16 个 epoch 左右趋于平稳，无明显过拟合现象；而 TSception 在微调过程中训练准确率持续上升但验证准确率停滞，表现出典型的过拟合特征。




图 3.6 EEGNet 在竞赛数据上 5 折微调的训练与验证曲线

3.5 测试集推理

基于最终测试方案，使用 EEGNet + LightGBM 融合模型对 10 名测试被试的脑电数据进行推理预测。测试数据按官方描述，每名被试包含 8 段情绪视频对应的 10 秒脑电片段（共 80 个 trial），预测结果以规定模板格式输出为 submission.xlsx 文件。

4 总结

4.1 核心技术成果

本文围绕小样本脑电情绪识别中的过拟合与跨被试泛化两大难题，构建了深度迁移学习与手工特征融合的双管线方案。在数据层面，竞赛数据与 DEAP 公开数据经统一的 0.5–50Hz 带通滤波、10 秒分段和 Z-score 标准化处理后，形成格式对齐的训练与预训练数据集。在特征层面，微分熵、功率谱密度和 Hjorth 参数三类共计 390 维手工特征将 75,000 维的原始信号空间压缩至 390 维，在保留已知情绪相关频域和时域信息的同时使下游分类器的统计学习成为可能。在模型层面，轻量级 EEGNet (2,834 参数) 和大容量 TSception (3,111,106 参数) 构成了一组容量-泛化关系的对照实验，手工特征与 LightGBM 的组合构成第二条独立管线，两条管线的软投票融合构成第三条路径。在验证层面，所有实验在 5 折 GroupKFold 按被试划分的策略下评估，以确保验证分数反映模型对陌生被试的泛化能力。实验结果表明：轻量级模型的泛化性能显著优于大容量模型 (63.96% vs 53.35%)，手工特征管线达到 62.19%，异构融合达到最高的 64.26%。DEAP 预训练未产生统计显著的增益，其根源在于源域与目标域在采样率、刺激材料和采集范式上的三重差异。特征重要性分析独立地识别出 γ 和 α 波段微分熵以及顶颞区电极 (通道 18、12、17、22) 为情绪分类的核心特征和通道，与神经科学文献形成独立一致。

4.2 算法设计的创新性

本方案在方法层面的贡献不在于提出全新的算法架构，而在于通过系统的实验设计回答了小样本脑电情绪识别中的三个递进问题。

一是模型容量的边界。将 TSception 和 EEGNet 置于完全相同的输入、划分和训练条件下进行对比，二者参数量相差约 1,100 倍，构成了一个天然的容量消融实验。实验结论 (容量更大的模型反而准确率低 10% 以上) 并非对 TSception 架构的否定，而是以量化方式界定了当前数据规模 (60 人，约 2,400 trial) 下模型容量的合理范围。这一发现对后续工作具有直接的工程参考价值：在数据规模未显著扩大的前提下，优先选择参数量与数据量匹配的轻量级架构。

二是迁移学习的边界。DEAP 预训练在两个模型上均未产生可测量的正面增益，这一“零结果”本身提供了明确的信息：当源域与目标域在采样率、刺激模态和采集范式上同时存在显著差异时，直接进行模型权重迁移的有效性受限。该结论将迁移学习的讨论从“是否有效”聚焦到“何种条件下有效”，为后续源域的选择提供了具体标准。

三是异构模型互补的验证。手工特征管线和深度学习管线在数据表示 (390 维结构

化特征 vs 原始波形）和学习机制（梯度提升树 vs 卷积网络）上完全不同，两种模型在 GroupKFold 验证中的错误样本集存在显著不重叠，软投票融合后准确率超出两个单独模型。该结果以实验方式验证了”不同学习范式的错误模式具有互补性”这一假设。

4.3 方案与模型的完整性

本文构建的脑电情绪识别管线覆盖了从原始数据到最终分类决策的完整链路。预处理阶段，竞赛数据与 DEAP 数据经过统一的通道对齐、带通滤波、滑动窗分段和 Z-score 标准化，两条数据管线在频域条件和信号统计特性上保持一致，为后续的跨数据集迁移学习提供了统一的数据基础。特征工程阶段，三类手工特征分别覆盖频域能量（PSD）、频域统计结构（DE）和时域波形形态（Hjorth 参数），从三个互补的视角提取情绪相关的脑电信息，合计 390 维。模型训练阶段，并行构建了手工特征 +LightGBM 和原始信号 +EEGNet 两条管线，并设置了 TSception 作为容量对照、DEAP 预训练 + 微调作为迁移学习对照。验证阶段，通过预训练效果消融、模型容量消融和特征贡献分析三项消融实验，逐组件量化了每个设计决策的边际效应。全流程代码从数据预处理、特征提取、模型训练、交叉验证到测试集推理均可复现运行。

4.4 本地可验证的性能

性能评估建立在严格的跨被试验证框架之上。采用 5 折 GroupKFold 按被试划分策略，划分的原子单位是被试而非 trial，确保同一被试的数据不会被拆分至训练集和验证集两侧。全部对比方法使用完全相同的 5 折随机划分（固定随机种子），排除了数据划分差异对方法间比较的干扰。

在该验证框架下，六组方法在 5 折 CV 中的平均准确率范围为 53.35% 至 64.26%。各方法的跨折标准差在 0.84% 至 2.87% 之间，反映了模型在不同被试组上的性能波动幅度。融合模型的标准差（ $\pm 1.45\%$ ）低于两个单独模型（EEGNet $\pm 2.06\%$ ，LightGBM $\pm 1.91\%$ ），表明融合策略在提升准确率的同时也增强了跨被试的稳定性。训练过程的收敛曲线（图 3.5、图 3.6）显示 EEGNet 在预训练和微调阶段均正常收敛，未出现训练-验证曲线显著分离的过拟合特征；而 TSception 的曲线则出现了训练准确率持续上升、验证准确率停滞的典型过拟合模式，与容量消融的结论相互印证。

4.5 展望

本工作揭示了若干有待进一步探索的方向。在预训练数据方面，DEAP 与竞赛数据之间的域鸿沟限制了迁移学习的收益，引入 SEED、DREAMER 等在采样率和采集范式上更接近竞赛数据的公开数据集，有望突破当前预训练策略的性能瓶颈。在模型架构方

面，STAFNet^[12]、DAMGCN 等集成了注意力机制和图神经网络的最新架构在公开数据集上取得了领先性能，但其参数量通常较高，在小样本场景下的适用性需配合针对性的正则化和容量控制策略进行验证。在可解释性方面，Grad-CAM 和 SHAP 等方法可将模型的时间-空间关注区域可视化，为特征重要性分析提供更细粒度的补充证据。在训练范式方面，自监督对比学习可利用大规模无标注脑电数据预训练表征编码器，降低对有标注数据的依赖，在脑电情绪识别领域具有潜在的应用前景。

参考文献

- [1] Lawhern, V.J. et al. (2018). EEGNet: A Compact Convolutional Neural Network for EEG-based Brain-Computer Interfaces. *Journal of Neural Engineering*.
- [2] Ding, Y. et al. (2023). TSception: Capturing Temporal Dynamics and Spatial Asymmetry from EEG for Emotion Recognition. *IEEE Transactions on Affective Computing*.
- [3] Koelstra, S. et al. (2012). DEAP: A Database for Emotion Analysis Using Physiological Signals. *IEEE Transactions on Affective Computing*.
- [4] Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *NeurIPS*.
- [5] Klem, G.H. et al. (1999). The Ten-Twenty Electrode System of the International Federation. *Electroencephalography and Clinical Neurophysiology*, 52(3): 3–6.
- [6] Bigdely-Shamlo, N. et al. (2015). The PREP Pipeline: Standardized Preprocessing for Large-Scale EEG Analysis. *Frontiers in Neuroinformatics*, 9: 16.
- [7] Butterworth, S. (1930). On the Theory of Filter Amplifiers. *Experimental Wireless and the Wireless Engineer*, 7: 536–541.
- [8] Duan, R.N., Zhu, J.Y., Lu, B.L. (2013). Differential Entropy Feature for EEG-based Emotion Classification. *Proceedings of the 6th International IEEE/EMBS Conference on Neural Engineering (NER)*, 81–84.
- [9] Coan, J.A. and Allen, J.J.B. (2004). Frontal EEG Asymmetry as a Moderator and Mediator of Emotion. *Biological Psychology*, 67(1–2): 7–50.
- [10] Welch, P.D. (1967). The Use of Fast Fourier Transform for the Estimation of Power Spectra. *IEEE Transactions on Audio and Electroacoustics*, 15(2): 70–73.
- [11] Hjorth, B. (1970). EEG Analysis Based on Time Domain Properties. *Electroencephalography and Clinical Neurophysiology*, 29(3): 306–310.
- [12] Hu, X. et al. (2024). STAFNet: An Adaptive Multi-Feature Learning Network via Spatiotemporal Fusion for EEG-based Emotion Recognition. *Frontiers in Neuroscience*.